Trabajo Práctico 2: Reconstrucción 3D

I308 – Visión Artificial, Universidad de San Andrés

Luis Embon Strizzi · Franco Sandri · Alan Yeger

Octubre de 2026

Resumen. Se presenta la reconstrucción tridimensional de un peluche a partir de 27 pares de imágenes tomados con una cámara estéreo en una órbita completa alrededor del objeto, apoyado sobre un tablero ChArUco que define el marco de referencia global. El sistema estéreo se calibró con la herramienta de la cátedra, con un error de reproyección de 1,25 px, y su escala métrica se verificó de forma independiente triangulando las esquinas del tablero, cuyo lado se recupera con un error del 0,3 %. Sobre cada par rectificado se calcula un mapa de disparidad con SGBM, cuyos parámetros se ajustaron de forma interactiva con `stereodemo` y se compararon con la red neuronal CREStereo. Cada mapa se convierte en una nube de puntos local mediante la matriz de reproyección Q, la pose de la cámara se estima con `solvePnP` sobre las esquinas del tablero y las nubes se transforman al marco global teniendo en cuenta la rotación introducida por la rectificación. La nube fusionada, de 9,3 millones de puntos, se reduce a unos 176 000 mediante filtrado espacial, submuestreo por vóxeles y eliminación de puntos espurios en Open3D. Sobre el resultado se estima un alto de 280 mm y un ancho de 294 mm, con errores relativos del 3,5 y el 2,0 % respecto de las medidas reales del objeto. Como paso opcional, se obtuvo además una malla de la superficie mediante la reconstrucción de Poisson.

1. Introducción y marco teórico

El objetivo del trabajo es obtener la nube de puntos 3D de un objeto a partir de varios pares de imágenes estéreo y estimar sus dimensiones en milímetros. A diferencia de la reconstrucción con una única cámara en movimiento, que recupera la escena sólo salvo un factor de escala, un sistema estéreo calibrado conoce la distancia entre sus dos cámaras y, por lo tanto, mide profundidades en unidades métricas. La reconstrucción completa requiere además observar el objeto desde todos sus lados y expresar cada vista en un marco común, que en este trabajo está dado por un tablero de calibración visible en todas las capturas. En esta sección se resumen los conceptos sobre los que se apoya el pipeline.

1.1. Modelo de cámara y calibración

En el modelo *pinhole*, un punto $\mathbf{X}$ expresado en el marco del mundo se proyecta en el píxel

$$\tilde{\mathbf{x}} \simeq K\,[R \mid \mathbf{t}]\,\tilde{\mathbf{X}}, \qquad K = \begin{pmatrix} f_x & 0 & c_x \\ 0 & f_y & c_y \\ 0 & 0 & 1 \end{pmatrix}, \tag{1}$$

donde $\simeq$ denota igualdad salvo escala en coordenadas homogéneas. Los **parámetros extrínsecos** $(R, \mathbf{t})$ describen la pose de la cámara respecto del mundo, mientras que los **intrínsecos**, reunidos en K, son propios de la cámara: las distancias focales f_x, f_y expresadas en píxeles y el punto principal (c_x, c_y), intersección del eje óptico con el sensor. Las lentes reales se apartan de este modelo; OpenCV modela la distorsión radial y tangencial con cinco coeficientes $(k_1, k_2, p_1, p_2, k_3)$, que desplazan cada punto normalizado en función de su distancia r al centro, por ejemplo $x_d = x(1 + k_1 r^2 + k_2 r^4 + k_3 r^6) + 2p_1 xy + p_2(r^2 + 2x^2)$.

Ninguno de estos parámetros es conocido de antemano con la precisión necesaria, por lo que deben **calibrarse**. El método de Zhang [2] utiliza un patrón plano de geometría conocida, como un tablero de ajedrez, fotografiado en distintas posiciones: cada esquina detectada provee una correspondencia entre un punto 3D conocido y su proyección, y los parámetros se ajustan por mínimos cuadrados no lineales minimizando el **error de reproyección**

$$E_{\mathrm{RMS}} = \sqrt{\frac{1}{N}\sum_{i} \left\| \mathbf{x}_i - \pi(K, \mathbf{d}, R_j, \mathbf{t}_j, \mathbf{X}_i) \right\|^2}, \tag{2}$$

es decir, la distancia media cuadrática, en píxeles, entre las esquinas detectadas $\mathbf{x}_i$ y las que predice el modelo calibrado. Un valor del orden de un píxel o menor indica que el modelo explica adecuadamente las observaciones.

1.2. Calibración estéreo

En un sistema estéreo se calibran ambas cámaras y, además, su **pose relativa**: la rotación R y la traslación $\mathbf{T}$ que llevan un punto del marco de la cámara izquierda al de la derecha, $\mathbf{X}_R = R\,\mathbf{X}_L + \mathbf{T}$. La norma $B = \|\mathbf{T}\|$ es la **línea de base**, y como el tablero se describe en milímetros, B queda expresada en esa unidad y fija la escala métrica de toda la reconstrucción. La función `cv2.stereoCalibrate` estima simultáneamente los intrínsecos, la distorsión de cada cámara y $(R, \mathbf{T})$, minimizando el error de reproyección de la Ec. (2) sobre las esquinas detectadas en ambas imágenes de cada par. Como subproducto entrega la matriz esencial $E = [\mathbf{T}]_\times R$ y la fundamental $F = K_R^{-\top} E K_L^{-1}$.

1.3. Geometría epipolar y rectificación

Dado un píxel $\mathbf{x}_L$ en la imagen izquierda, su correspondiente en la derecha no puede estar en cualquier lugar: el punto 3D se encuentra sobre el rayo que pasa por el centro óptico izquierdo y $\mathbf{x}_L$, y la proyección de ese rayo en la cámara derecha es la **recta epipolar** $\mathbf{l}_R = F\tilde{\mathbf{x}}_L$, de modo que $\tilde{\mathbf{x}}_R^\top F \tilde{\mathbf{x}}_L = 0$ [1]. La búsqueda de correspondencias se reduce así a una dimensión. La **rectificación estéreo** (`cv2.stereoRectify`) aplica a cada cámara una rotación virtual, R_1 y R_2, y una matriz intrínseca común, de manera que ambos planos imagen resulten coplanares y paralelos a la línea de base. En las imágenes rectificadas, que se obtienen además sin distorsión mediante `initUndistortRectifyMap` y `remap`, las rectas epipolares son horizontales y coinciden fila a fila: el correspondiente de un píxel se busca en la misma fila de la otra imagen. Esto es lo que hace posible y eficiente el cálculo denso de disparidad.

1.4. De la disparidad a la profundidad

En un par rectificado, la **disparidad** de un punto es la diferencia horizontal entre sus proyecciones, $d = x_L - x_R$. Por semejanza de triángulos entre los dos rayos y la línea de base, la profundidad resulta

$$Z = \frac{f\,B}{d}, \qquad X = \frac{(u - c_x)\,Z}{f}, \qquad Y = \frac{(v - c_y)\,Z}{f}, \tag{3}$$

con f y (c_x, c_y) los parámetros de la cámara rectificada. La profundidad es inversamente proporcional a la disparidad, por lo que su incertidumbre crece con el cuadrado de la distancia: derivando, $\delta Z = Z^2\,\delta d/(fB)$. La rectificación devuelve además

la matriz de reproyección Q, de 4×4, que implementa la Ec. (3) en coordenadas homogéneas: $[X\ Y\ Z\ W]^\top = Q\,[u\ v\ d\ 1]^\top$, y es la que utiliza `cv2.reprojectImageTo3D`.

1.5. Conjunto de datos

Se utilizó un conjunto propio, capturado con la cámara estéreo ELP-USB3D1080P02 de la cátedra en modo 2560×720 (dos imágenes de 1280×720 sincronizadas). Comprende 30 pares de un tablero de ajedrez de 10×7 casilleros de 28 mm (9×6 esquinas internas) para la calibración, y 27 pares de un peluche apoyado sobre un tablero ChArUco, tomados en una órbita completa a su alrededor. El tablero ChArUco (diccionario `DICT_5X5_100`, 9×13 casilleros de 42,0 mm, marcadores de 31,5 mm) combina la precisión de las esquinas de un tablero de ajedrez con la identificación unívoca de los marcadores ArUco [5], lo que permite estimar la pose aun cuando el objeto ocluye buena parte del patrón.

2. Metodología

El pipeline se implementó en Python con OpenCV 4.13 y Open3D 0.20, en un notebook con funciones auxiliares en un módulo aparte. La Fig. 1 resume sus etapas, que se describen a continuación.

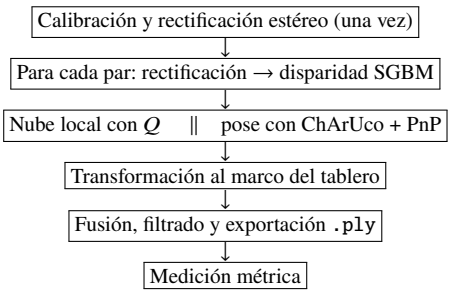


Figura 1: Etapas del pipeline de reconstrucción.

2.1. Calibración y rectificación

La calibración se realizó con la herramienta `calib-stereo` de la cátedra, que detecta el tablero en vivo, acumula las vistas y ejecuta `stereoCalibrate` y `stereoRectify`. Se capturaron 30 pares a 1280×720 procurando cubrir todo el campo visual, en particular los bordes, donde la distorsión es mayor. La herramienta guarda los parámetros y los mapas de rectificación, pero no el error de reproyección; para informarlo se repitió la calibración en el notebook con las mismas imágenes y `cv2.stereoCalibrate`, siguiendo el procedimiento del Tutorial 6 (detección con `findChessboardCorners`, refinamiento subpíxel con `cornerSubPix`). Que los parámetros obtenidos coincidan con los de la herramienta garantiza que el error informado corresponde a la calibración utilizada.

Además se validó la calibración con datos independientes, las capturas del objeto. En cada par se estimó la pose del tablero ChArUco con la cámara izquierda, se la trasladó a la derecha con $(R, \mathbf{T})$ y se midió el error de reproyección de sus esquinas en la imagen derecha, lo que evalúa conjuntamente intrínsecos y extrínsecos. También se triangularon las esquinas detectadas en ambas imágenes con las matrices de proyección rectificadas P_1, P_2 y se midió la distancia entre esquinas vecinas, que debe coincidir con el lado de 42 mm si la escala es correcta.

2.2. Mapa de disparidad

Se utilizó Semi-Global Block Matching (SGBM) [3], que compara bloques de píxeles a lo largo de la fila y agrega el costo en varias direcciones con penalizaciones P_1 y P_2 a los cambios de disparidad entre vecinos, lo que produce mapas más coherentes que el block matching local en zonas de poca textura. Los parámetros dependen de la cámara y de la escena, no de cada imagen, por lo que se fijaron una única vez para los 27 pares (Tabla 1). Se ajustaron de forma interactiva con la herramienta `stereodemo`, que muestra la disparidad y la nube resultante a medida que se modifican, sobre pares representativos. El rango de búsqueda se dedujo de la geometría: con $fB \approx 24\,422$ px · mm, la Ec. (3) indica que el objeto, a 25–60 cm de la cámara, tiene disparidades de 40–110 px; el intervalo $[8, 152)$ px cubre profundidades de 16 cm a 3 m. A modo de comparación se evaluó también CREStereo [4], una red neuronal de *matching* estéreo incluida en `stereodemo`. OpenCV devuelve la disparidad multiplicada por 16 en enteros; se la divide por 16 y se descartan los valores no válidos.

Parámetro	Valor	Justificación
`minDisparity`	8	Z entre 16 cm y 3 m
`numDisparities`	144	
`blockSize`	5	conserva bordes finos
`P1`, `P2`	600, 2400	sugeridos por OpenCV
`uniquenessRatio`	10	descarta ambigüedades
`speckleWindowSize`	200	elimina manchas aisladas
`speckleRange`	2	
`disp12MaxDiff`	1	consistencia izq.–der.
`mode`	`SGBM_3WAY`	más rápido, igual calidad

Tabla 1: Parámetros de SGBM utilizados para los 27 pares; $P_1 = 8\cdot3\cdot5^2$ y $P_2 = 32\cdot3\cdot5^2$ (tres canales, bloque de 5).

2.3. Nube de puntos local

Cada mapa de disparidad se convierte en una nube con `cv2.reprojectImageToD(d, Q)`, lo que da las coordenadas en milímetros en el marco de la cámara izquierda *rectificada*. Antes de acumular los puntos se aplican tres filtros por píxel: disparidad válida, profundidad entre 150 y 1000 mm, para descartar el fondo lejano, y eliminación de los **bordes de profundidad**. En las discontinuidades entre el objeto y el fondo, el *matching* mezcla ambas superficies y genera puntos intermedios que flotan en el aire (*flying pixels*); por eso se descartan los píxeles en cuyo entorno de 5×5 la disparidad varía más de 3 px. El color de cada punto se toma de la imagen izquierda rectificada.

2.4. Pose de la cámara y marco global

El marco global es el del tablero ChArUco: origen en una esquina, ejes x e y sobre el plano del tablero y eje z normal a él, de modo que el objeto queda en $z<0$. En la imagen izquierda original de cada par se detectan las esquinas del tablero con el detector ChArUco de OpenCV, que interpola sus posiciones a partir de los marcadores identificados; como cada esquina tiene un identificador, se conocen sus coordenadas en milímetros sobre el tablero ($z=0$). Con esas correspondencias 3D–2D y los intrínsecos de la cámara izquierda, `cv2.solvePnP` estima la pose $(\mathbf{r}, \mathbf{t})$ que minimiza el error de reproyección, tal que $\mathbf{X}_{cam} = R_{wc}\mathbf{X}_{mundo} + \mathbf{t}$. Se empleó la variante IPPE [6], específica para puntos coplanares, seguida de un refinamiento de Levenberg–Marquardt, y se descartaron iterativamente las esquinas con error de reproyección mayor que máx(2 px, 3 mediana), que corresponden a detecciones erróneas por oclusión parcial. Se descartaron los pares sin tablero detectable o con error de reproyección final superior a 2 px.

La rotación se obtiene como **vector de Rodrigues r**: su dirección $\mathbf{k} = \mathbf{r}/\|\mathbf{r}\|$ es el eje de giro y su norma $\theta = \|\mathbf{r}\|$ el ángulo, una representación mínima de tres parámetros que

`cv2.Rodrigues` convierte en la matriz $R_{wc} = I + \sin\theta\,[\mathbf{k}]_\times + (1-\cos\theta)[\mathbf{k}]_\times^2$.

Para llevar la nube local al marco global hay que tener en cuenta que no está expresada en la cámara izquierda original sino en la rectificada, que está rotada R_1 respecto de aquélla ($\mathbf{X}_{rect} = R_1\mathbf{X}_{cam}$; la rectificación no traslada el centro óptico izquierdo). Invirtiendo ambas transformaciones,

$$\mathbf{X}_{mundo} = R_{wc}^{\top}\big(R_1^{\top}\,\mathbf{X}_{rect} - \mathbf{t}\big), \tag{4}$$

y la posición de la cámara en el mundo es $\mathbf{C} = -R_{wc}^{\top}\mathbf{t}$. Aunque R_1 es una rotación pequeña (0,33° en nuestra calibración), omitirla desplaza puntos situados a 50 cm en casi 3 mm, del orden de la resolución buscada.

2.5. Fusión y optimización de la nube

Las nubes de todos los pares aceptados se acumulan en el marco global y se procesan con Open3D [7] en cinco pasos:

1. **Filtrado espacial.** Se construye una caja (`OrientedBoundingBox`) alineada con el tablero que encierra el objeto ($x \in [40, 360]$, $y \in [80, 500]$, $z \in [-360, -4]$ mm), con límites elegidos a partir de las dimensiones del tablero y de la nube, y se conservan los puntos interiores (`get_point_indices_within_bounding_box`, `select_by_index`).
2. **Submuestreo** con `voxel_down_sample` de 2 mm: las vistas se superponen y la nube es muy redundante; 2 mm conserva el detalle del pelaje y de las orejas.
3. **Eliminación de outliers**: se aplica primero un filtro estadístico, `remove_statistical_outlier` (30 vecinos, $1{,}5\,\sigma$), y luego uno por radio, `remove_radius_outlier` (al menos 12 vecinos en 6 mm), para los puntos aislados.
4. **Remoción del plano del tablero**: `segment_plane` (RANSAC, umbral de 10 mm) identifica el tablero que queda dentro de la caja y se lo elimina.
5. **Componente principal**: `cluster_dbscan` [8] (radio de 6 mm) agrupa los puntos y se conserva el grupo más numeroso, el objeto, lo que descarta restos desconectados.

Los pasos 1 a 3 son los que exige la consigna; los pasos 4 y 5 se agregaron porque el tablero ocupa la base de la caja y algunos restos sobreviven al filtrado estadístico. El resultado se exporta como `.ply` binario con `o3d.io.write_point_cloud`.

2.6. Mallado de la superficie (opcional)

Como paso opcional se obtuvo una malla triangular a partir de la nube final, en un notebook aparte que no modifica la nube ni la medición. Primero se estimaron las normales con `estimate_normals`: para cada punto se ajusta un plano a sus vecinos (radio de 10 mm, hasta 50 vecinos) por análisis de componentes principales, y la normal es la dirección de menor varianza. Ese ajuste determina la dirección pero no el sentido, por lo que las normales se orientaron de forma consistente con `orient_normals_consistent_tangent_plane`, que propaga el sentido entre vecinos, y luego hacia el exterior del objeto. Con ellas se aplicó la reconstrucción de Poisson [9] (`create_from_point_cloud_poisson`, profundidad 8, celdas de aproximadamente 1,5 mm), que busca una función indicadora del interior cuyo gradiente aproxime el campo de normales y extrae la superficie como una isosuperficie de esa función. Como Poisson siempre genera una superficie cerrada, completa también las zonas sin datos, como la base del objeto; para eliminarlas se descartó el 5 % de los vértices con menor densidad de puntos de soporte y se recortó la malla con la caja que encierra la nube. Por último se aplicó un suavizado de Taubin [10], que atenúa el ruido sin contraer la superficie, y se redujo la malla a 150 000 triángulos.

2.7. Medición métrica

El **alto** se midió como la distancia de cada punto al plano del tablero ajustado por RANSAC en el paso 4, tomando el percentil 99,5 para que unos pocos puntos espurios no lo inflen; se informa también el máximo. Se usó el plano ajustado y no el plano $z = 0$ de la pose por el sesgo que se discute en la Sec. 3.7. El **ancho** y la **profundidad** se obtuvieron proyectando los puntos sobre el plano del tablero y calculando el rectángulo de área mínima (`cv2.minAreaRect`) que encierra el 99 % central de ellos; el lado mayor corresponde al ancho entre las puntas de las orejas.

El resultado es métrico, y no definido salvo un factor de escala como en la reconstrucción con una sola cámara en movimiento, porque la escala ingresa por dos vías independientes: la línea de base B, obtenida en milímetros al calibrar con un tablero de dimensiones conocidas, fija las profundidades de la Ec. (3), y el tamaño impreso del ChArUco fija la traslación de cada pose. La verificación de la Sec. 3.1 muestra que ambas escalas son consistentes.

3. Resultados y discusión

	Izquierda	Derecha
f_x, f_y [px]	403,15; 400,56	401,72; 398,33
c_x, c_y [px]	635,81; 356,21	636,42; 348,63
k_1, k_2, k_3	−0,023; 0,032; −0,025	−0,018; 0,021; −0,018
$\mathbf{T}$ [mm]	$(-60{,}17;\ 0{,}10;\ -0{,}15)$, $B = 60{,}17$	
R	rotación de 0,39°	
Error RMS	1,25 px (29 pares)	

Tabla 2: Parámetros de la calibración estéreo (1280 × 720) obtenidos con la herramienta de la cátedra. Los coeficientes tangenciales son menores que $2 \cdot 10^{-3}$. El error RMS corresponde a la recalibración en el notebook con las mismas imágenes.

3.1. Calibración y rectificación

La calibración estéreo repetida en el notebook utilizó 29 de los 30 pares: en el par 7 no se detecta el tablero en la imagen izquierda, probablemente por un reflejo sobre los casilleros centrales. El **error de reproyección resultó de** 1,25 px, comparable al de 1,06 px que obtiene la cátedra con su propio conjunto de datos. Los parámetros coinciden con los de la herramienta (f_x izquierda de 402,05 frente a 403,15 px, una diferencia del 0,3 %; línea de base de 60,18 frente a 60,17 mm), y la Tabla 2 resume los valores utilizados. La rotación entre cámaras es de apenas 0,39° y la traslación es prácticamente horizontal, como corresponde a una cámara estéreo de cuerpo rígido. Tras la rectificación ambas cámaras comparten $f = 405{,}9$ px y $(c_x, c_y) = (631{,}0;\ 352{,}4)$, de modo que $fB = 24\,422$ px · mm.

La validación con el tablero ChArUco sobre las capturas del objeto dio un error de reproyección de 0,48 px en la imagen izquierda, donde se estima la pose, y de 1,31 px en la derecha, a la que la pose se traslada con $(R, \mathbf{T})$, un valor coherente con el error de calibración. El lado de los casilleros triangulados resultó de 42,13 mm (mediana; media 42,11 ± 1,32 mm), frente a 42,0 mm reales, un error del 0,3 % que confirma que la reconstrucción es métrica.

La Fig. 2 muestra un par antes y después de rectificar: la rectificación corrige la leve distorsión de la lente y alinea las filas, de manera que los mismos detalles caen sobre las líneas

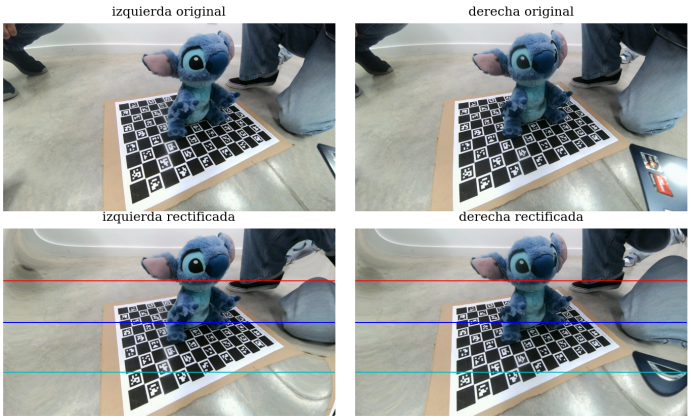


Figura 2: Par 13 antes (arriba) y después (abajo) de la rectificación. En las imágenes rectificadas los puntos correspondientes se encuentran en la misma fila, lo que se aprecia con las líneas horizontales de referencia.

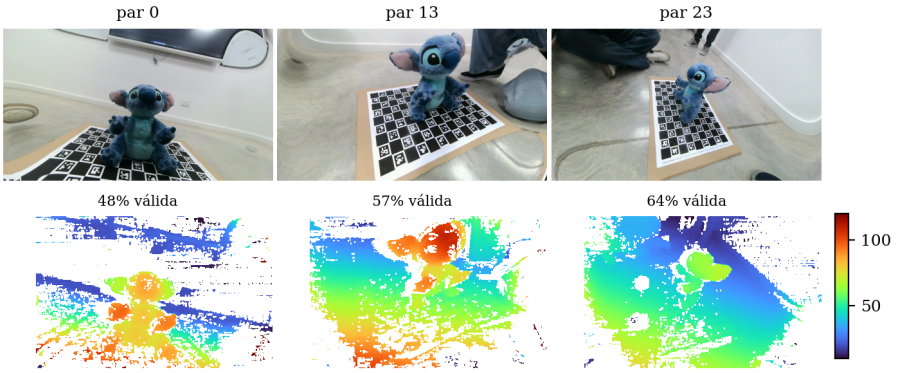


Figura 3: Arriba: imagen izquierda rectificada de tres pares. Abajo: disparidad calculada con SGBM (en blanco, píxeles sin disparidad válida) y porcentaje de píxeles válidos.

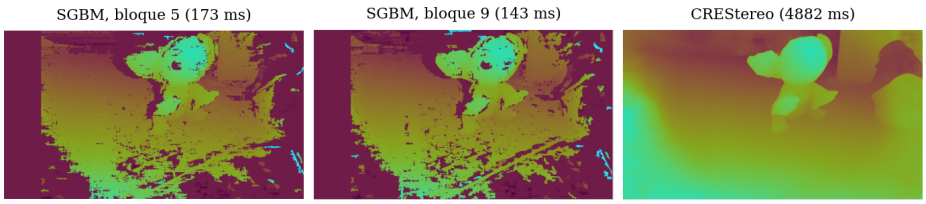


Figura 4: Disparidad del par 13 obtenida en `stereodemo` con SGBM (bloques de 5 y 9 píxeles) y con CREStereo, junto con el tiempo de cómputo. El color violeta oscuro indica disparidad no válida en SGBM.

horizontales en ambas imágenes. Al medir la diferencia vertical entre esquinas correspondientes se encontró, sin embargo, un desfasaje residual de 0,2 a 1,5 px, siempre del mismo signo y mayor en los pares en que el tablero aparece cerca del borde de la imagen.

3.2. Disparidad

La Fig. 3 presenta los mapas de disparidad de SGBM para tres pares tomados desde posiciones distintas. El objeto se recupera casi completo y bien separado del fondo, con disparidades de 40 a 110 px, mientras que el piso muestra el gradiente suave esperable para un plano que se aleja. La fracción de píxeles con disparidad válida es del 48 al 64 %; los huecos se concentran en la pared blanca, que carece de textura, en el ojo del peluche, cuyo brillo especular difiere entre ambas cámaras, en las zonas ocluidas para una de las cámaras (por ejemplo, entre los brazos y el cuerpo) y en la franja izquierda de la imagen, donde no existe correspondencia posible.

Como método de *matching* se adoptó **SGBM**, tras compararlo en `stereodemo` con la red neuronal CREStereo sobre el par 13 (Fig. 4). CREStereo produce un mapa más denso, sin huecos y con contornos nítidos, pero presenta dos desventajas que motivaron su descarte. La primera es el costo: requiere 4,9 s por par, unas 30 veces más que SGBM (0,14 a 0,17 s), aun operando a una resolución reducida de 640×480. La segunda, más relevante para una medición métrica, es que asigna disparidad a regiones sin textura, como la pared, en las que no existe información para estimarla: interpola valores plausibles que no provienen de una correspondencia real. SGBM, en cambio, deja esas regiones sin valor, de modo que cada punto de la nube surge de una correspondencia efectivamente observada, y los huecos que deja se cubren con las otras 23 vistas.

Dentro de SGBM, la misma comparación fijó el tamaño de bloque en 5 píxeles. Un bloque de 9 produce un mapa más suave, pero ensancha los bordes del objeto y pierde detalles finos; con 5 se conservan los contornos de las orejas a costa de pequeños huecos, que la redundancia entre vistas compensa. El tiempo de cómputo no depende apreciablemente del tamaño de bloque.

3.3. Nube local, poses y marco global

La nube local del par 13 contiene 400 729 puntos, el 43 % de los píxeles (Fig. 5). La conversión de `reprojectImageTo3D` coincide exactamente con la Ec. (3): por ejemplo, un píxel con $d = 55{,}00$ px resulta a $Z = 444{,}0$ mm. El tablero aparece plano y el peluche se destaca con volumen sobre él, junto con restos

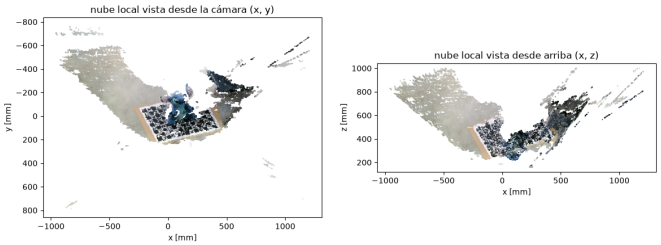


Figura 5: Nube local del par 13 en el marco de la cámara izquierda rectificada, vista desde la cámara (izquierda) y desde arriba (derecha).



Figura 6: Esquinas ChArUco detectadas (verde, con su identificador) y ejes del marco global proyectados con la pose estimada (par 22).

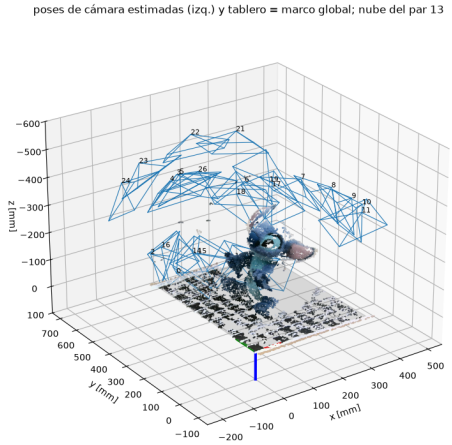


Figura 7: Poses estimadas de la cámara izquierda en el marco del tablero (gris), con su número de par, y nube del par 13 transformada al marco global.

del piso y de las personas presentes, que se eliminan en la etapa de fusión.

La Fig. 6 muestra la detección del tablero en una de las capturas: aun con el objeto ocluyendo parte del patrón se identifican 32 esquinas y la pose tiene un error de reproyección de 0,24 px. Se aceptaron 24 de los 27 pares: en los pares 1 y 25 no se detectaron suficientes esquinas del tablero (se exigen al menos ocho) y en el par 20 la pose presentó un error de 6,1 px. En los pares aceptados el error de reproyección de PnP estuvo entre 0,23 y 1,80 px. La Fig. 7 representa las poses estimadas en el marco global: las cámaras forman una órbita alrededor del tablero, a entre 19 y 55 cm por encima de su plano, en concordancia con el recorrido realizado durante la captura. La nube del par 13 transformada con la Ec. (4) queda correctamente apoyada sobre el tablero.

3.4. Fusión y optimización

La Tabla 3 indica la cantidad de puntos que sobrevive a cada etapa y la Fig. 8 muestra la nube antes de optimizar, después del filtrado espacial y al final del proceso. La nube global de 9,3 millones de puntos contiene el piso, las personas y el mobiliario del aula; la caja conserva el 16 % de los puntos y el submuestreo los reduce a la sexta parte, lo que confirma la gran redundancia entre vistas. El filtrado de outliers elimina

Etapa	Puntos	Fracción
Nube global (24 pares)	9 282 487	100 %
1. Caja	1 510 554	16,3 %
2. Vóxeles de 2 mm	239 309	2,6 %
3. Outliers (estadístico + radio)	233 096	2,5 %
4. Sin plano del tablero	180 711	1,9 %
5. Componente principal (final)	175 791	1,9 %

Tabla 3: Puntos que sobreviven a cada etapa de la optimización.

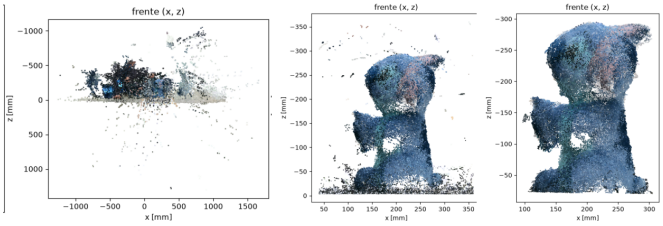


Figura 8: Vista frontal (x–z) de la nube global antes de optimizar (izquierda; nótese la escala), después del filtrado espacial (centro) y al final del proceso (derecha). El eje z crece hacia el interior del tablero.

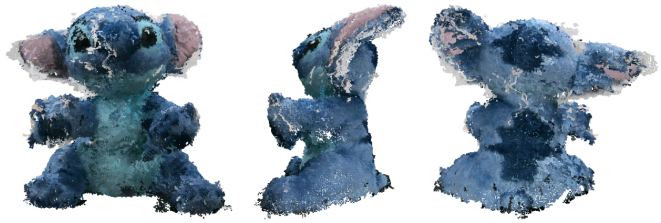


Figura 9: Nube final optimizada visualizada en MeshLab: vistas frontal, lateral y posterior.

pocos puntos, porque los filtros por píxel de la etapa local ya habían descartado la mayoría de los espurios, y la remoción del plano y el agrupamiento separan el tablero y los restos sueltos. La nube final tiene 175 791 puntos y el archivo `.ply` binario ocupa 4,7 MB.

La Fig. 9 muestra la nube final abierta en MeshLab, lo que verifica la validez del archivo exportado. La reconstrucción cubre el objeto en sus 360°, incluida la espalda, gracias a que el tablero ChArUco permitió estimar la pose incluso desde los lados en que el peluche lo ocluye parcialmente.

3.5. Malla de Poisson

La Fig. 10 muestra la malla obtenida, de 74 102 vértices y unos 150 000 triángulos, exportada como un archivo `.ply` aparte de 5,7 MB. La malla recupera la forma completa del objeto, incluida la espalda, y se mantiene próxima a los datos: la distancia de cada vértice al punto más cercano de la nube tiene una mediana de 1,0 mm y un percentil 95 de 2,0 mm, del orden del tamaño de vóxel. La vista sombreada pone de manifiesto una superficie rugosa, porque la malla reproduce el ruido de la nube (el pelaje y el leve engrosamiento debido a la fusión de vistas), que el suavizado atenúa pero no elimina. Además, la malla no es cerrada: la base y el hueco entre el brazo y el cuerpo, que ninguna cámara observó con claridad, quedan abiertos porque el recorte por densidad elimina la superficie que Poisson completa sin datos que la sustenten. La medición de la sección siguiente se realizó sobre la nube de puntos, no sobre la malla.

3.6. Medición métrica

Sobre la nube final se obtuvo un **alto de** 279,7 mm (máximo 286,0 mm), un **ancho de** 294,0 mm entre las puntas de las orejas y una profundidad de 172,5 mm (Fig. 11). Medido con regla, el peluche tiene un alto de 290 mm, un ancho de 300 mm y una profundidad de 170 mm, por lo que los errores relativos son de −3,5 %, −2,0 % y +1,4 %, respectivamente. El alto y el

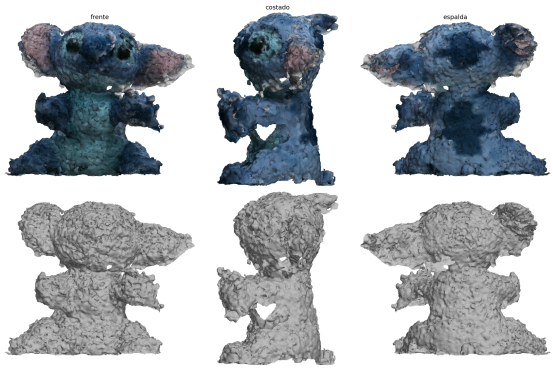


Figura 10: Malla obtenida con la reconstrucción de Poisson, vista de frente, de costado y de espalda: con el color de la nube (arriba) y en gris con sombreado (abajo), que deja ver la geometría.

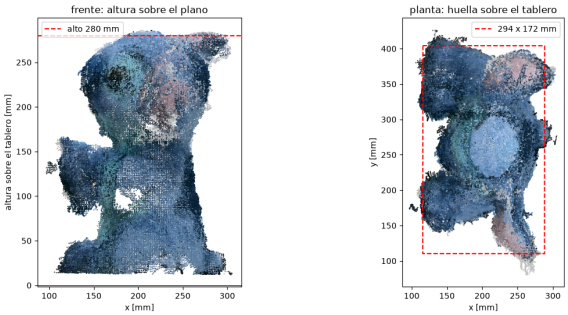


Figura 11: Medición sobre la nube final. Izquierda: altura de cada punto sobre el plano del tablero y alto estimado (percentil 99,5). Derecha: huella sobre el tablero y rectángulo de área mínima.

ancho resultan algo menores que los reales por dos motivos. Por un lado, la medición descarta a propósito los extremos: el alto es el percentil 99,5 de la distancia al plano (con el máximo, 286,0 mm, el error se reduce a $-1{,}4$ %) y el rectángulo encierra el 99 % central de la huella, por lo que se pierden las puntas de las orejas. Por otro, el filtro de bordes de profundidad y la eliminación de outliers descartan los puntos más dispersos del contorno, que es justamente donde está el pelaje que la regla sí alcanza.

3.7. Discusión

El pipeline produce una reconstrucción completa y métrica del objeto, pero el análisis de los resultados intermedios pone de manifiesto varias limitaciones.

Calibración y rectificación. El desfasaje vertical residual de 0,2 a 1,5 px entre imágenes rectificadas tiene siempre el mismo signo, lo que indica un error sistemático de la calibración y no ruido de detección. Que sea mayor cuando el tablero está en el borde de la imagen sugiere que el modelo de distorsión está peor determinado en esa zona, por falta de vistas de calibración que la cubran. SGBM busca correspondencias sólo en la misma fila, por lo que este desfasaje degrada el *matching* en los bordes; recalibrar con más vistas en las esquinas del campo visual permitiría reducirlo.

Consistencia entre escalas. El plano del tablero reconstruido por estéreo quedó 10,4 mm por encima del plano $z = 0$ que define la pose de PnP, alrededor del 2 % de la distancia de trabajo. Ambas mediciones son métricas pero no exactamente consistentes: la profundidad estéreo depende de f, B y de la rectificación, mientras que la pose depende de los intrínsecos de la cámara izquierda y del tamaño del tablero, y los errores residuales de calibración afectan a cada una de manera distinta. Por esta razón el alto se midió respecto del plano ajustado, lo que cancela el sesgo. Al fusionar vistas desde distintas direcciones, este tipo de error se traduce en un leve engrosamiento de las superficies.

Disparidad. La resolución en profundidad empeora con la distancia según $\delta Z = Z^2 \delta d/(fB)$: un error de un píxel de disparidad equivale a 3,7 mm a 30 cm y a 12 mm a 55 cm, de modo que las vistas cercanas aportan los puntos más precisos. Los huecos debidos al brillo del ojo y a las oclusiones se compensan sólo parcialmente con otras vistas; persiste, por ejemplo, un hueco entre el brazo y el cuerpo, que ninguna cámara observó con claridad. Los métodos basados en redes neuronales, como CREStereo, completarían esas zonas a un costo de cómputo mucho mayor y con el riesgo de introducir estructura inexistente.

Puntos espurios. En el contorno de las orejas se observan puntos de color gris, provenientes del fondo, que el filtro de bordes de profundidad no eliminó por completo: son *flying pixels* en los que la disparidad varía de forma gradual. También sobreviven restos del tablero bajo la base del objeto, cerca del umbral de 10 mm de la remoción del plano, que a su vez elimina los últimos milímetros de la base.

Poses. El par 19 se aceptó con una pose menos confiable (error de reproyección de 1,80 px, tras descartar 12 de 38 esquinas). El par 1 se encuentra en el límite de detección: según la versión de OpenCV se detectan 10 esquinas, y el par se acepta, o menos de ocho, y se descarta. Incluirlo o no modifica el alto en sólo 0,2 mm (279,9 frente a 279,7 mm), lo que indica que el resultado no depende de pares individuales. Un refinamiento de las poses con ICP entre nubes vecinas, o una optimización conjunta de todas ellas, reduciría el efecto de los pares menos confiables y del sesgo entre escalas.

Conclusión. El sistema estéreo calibrado, junto con el tablero ChArUco como referencia común, permitió reconstruir el objeto en sus 360° y medirlo con escala métrica: el lado del casillero se recupera con un error del 0,3 % y las dimensiones del objeto, con errores relativos de 3,5 % en el alto y 2,0 % en el ancho respecto de las medidas reales. La reconstrucción de Poisson permitió además obtener una superficie continua, fiel a la nube dentro de unos 2 mm. Como mejoras se proponen recalibrar cubriendo mejor los bordes del sensor y refinar las poses con ICP, lo que reduciría el engrosamiento de las superficies y, con él, la rugosidad de la malla.

Referencias

[1] R. Hartley y A. Zisserman, *Multiple View Geometry in Computer Vision*, 2.ª ed., Cambridge University Press, 2004.

[2] Z. Zhang, “A flexible new technique for camera calibration”, *IEEE TPAMI*, 22(11):1330–1334, 2000.

[3] H. Hirschmüller, “Stereo processing by semiglobal matching and mutual information”, *IEEE TPAMI*, 30(2):328–341, 2008.

[4] J. Li et al., “Practical stereo matching via cascaded recurrent network with adaptive correlation”, *CVPR*, 2022.

[5] S. Garrido-Jurado et al., “Automatic generation and detection of highly reliable fiducial markers under occlusion”, *Pattern Recognition*, 47(6):2280–2292, 2014.

[6] T. Collins y A. Bartoli, “Infinitesimal plane-based pose estimation”, *IJCV*, 109(3):252–286, 2014.

[7] Q.-Y. Zhou, J. Park y V. Koltun, “Open3D: A modern library for 3D data processing”, *arXiv:1801.09847*, 2018.

[8] M. Ester et al., “A density-based algorithm for discovering clusters in large spatial databases with noise”, *KDD*, 1996.

[9] M. Kazhdan, M. Bolitho y H. Hoppe, “Poisson surface reconstruction”, *Eurographics Symposium on Geometry Processing*, 2006.

[10] G. Taubin, “A signal processing approach to fair surface design”, *SIGGRAPH*, 1995.